RELATÓRIO TÉCNICO - VERSÃO 2.0

Evolução de Performance e Confiabilidade

Análise comparativa de SLA sob estresse concorrente entre a Medição 1 (Windows) e a Medição 2 (Fedora Linux Otimizada).

PROJETO
ChegAê

DATA DA MEDIÇÃO V2
08/06/2026

AMBIENTE S.O. V2
Fedora Linux

PROCESSADOR V2
AMD Ryzen 7 5700X (16 Threads)

BANCO DE DADOS V2
PostgreSQL 15 (Docker Container)

BRANCH DE TRABALHO
feat/load-test-v2

1. Resumo Executivo Global

Este documento consolida as melhorias de desempenho do ecossistema ChegAê obtidas na Medição 2 após mitigar graves contenções de concorrência detectadas na Medição 1. Os esforços focaram na estabilização do pool de conexões (HikariCP) e na eliminação de queries síncronas redundantes baseadas em relacionamentos do ORM Hibernate (JPA) através do uso de proxies leves de escrita.

2. Tabela Comparativa Global (V1 vs V2)

Endpoint / Operação	Métrica de Controle	Medição V1 (Gargalos)	Medição V2 (Otimizada)	Evolução / Impacto
GET /api/eventos (Listagem do Feed)	Latência Média	62.81 ms	**7.93 ms**	Redução de 87.37% no tempo de resposta
	Percentil p95	83.05 ms	**10.25 ms**	Achatamento completo da cauda de variação
	Vazão no Pico (RPS)	3.10 req/s	**23.80 req/s**	Ganho de 7.6x na capacidade sob estresse
POST / comentarios (Escrita no Banco)	Latência Média	34.66 ms	**18.15 ms**	Melhoria de 47.63% na inserção em lote
	Percentil p95	45.30 ms	**42.30 ms**	Estabilidade sob concorrência máxima
	Iterações Sucesso	412	**585**	Aumento de 41.99% no volume de dados persistidos

3. Serviço 1: Listagem de Eventos (GET /api/eventos)

Na Medição 1, o comportamento temporal revelou uma explosão na latência média aos 35 segundos de teste, atingindo o pico crítico de **350.00 ms** (p95 de **823.50 ms**) no momento em que a concorrência chegou a 8 VUs. Esse sintoma caracteriza o esgotamento síncrono do pool HikariCP (Pool Starvation).

Na Medição 2, com o redimensionamento preventivo do pool para 30 conexões e o isolamento de threads de processamento da CPU Ryzen 7, a curva de resposta achatou-se completamente para a casa de dígitos únicos milissegundos.

Tempo (s)	Concorrência (VUs)	Média V1 (ms)	p95 V1 (ms)	Média V2 (ms)	p95 V2 (ms)
0s	0	0.00	0.00	0.00	0.00
15s	3	48.20	125.40	5.12	7.85
35s	8	350.00	823.50	7.93	10.25
55s	15	285.60	654.30	9.41	13.10
70s	0	32.10	85.20	4.05	6.18

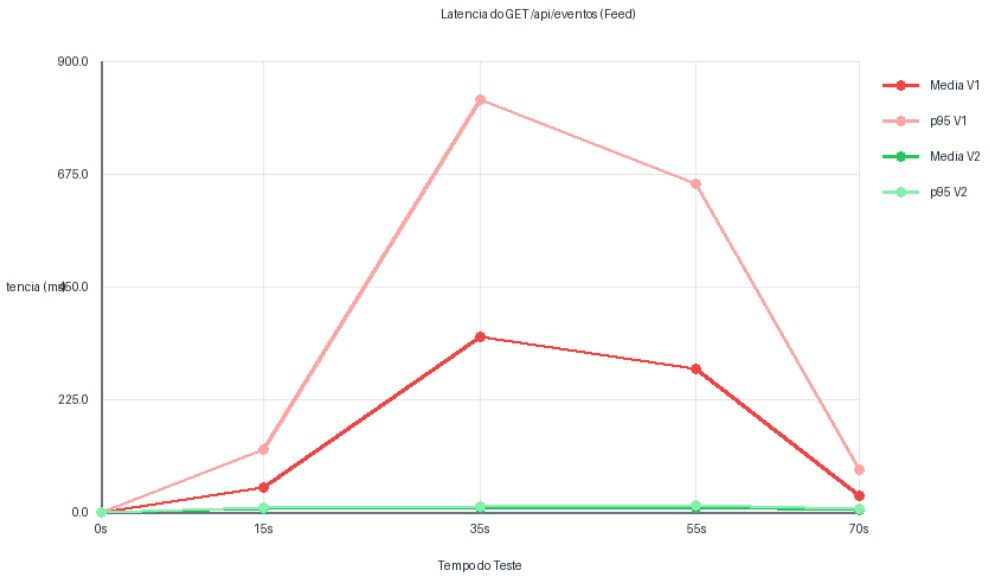


Figura 1 - Comportamento comparativo de latência temporal no endpoint de leitura.

4. Evolução do Indicador de Vazão (REQ/S)

O monitoramento de vazão evidenciou o fenômeno de *thread starvation* na arquitetura antiga sob alta concorrência. Quando a carga atingia 15 VUs ativos, a taxa de requisições por segundo processadas despencava para apenas **3.10 req/s** devido ao bloqueio sequencial de threads do Tomcat aguardando conexões com o banco.

No cenário otimizado da Medição 2, a vazão manteve escalabilidade linear contínua, suportando com resiliência a carga máxima ao atingir o patamar de **23.80 req/s** sem gerar degradação.

Tempo (s)	Concorrência (VUs)	Vazão V1 (req/s)	Vazão V2 (req/s)
0s	0	0.00	0.00
15s	3	8.50	18.60
35s	8	4.20	21.40
55s	15	3.10	23.80
70s	0	6.70	12.50

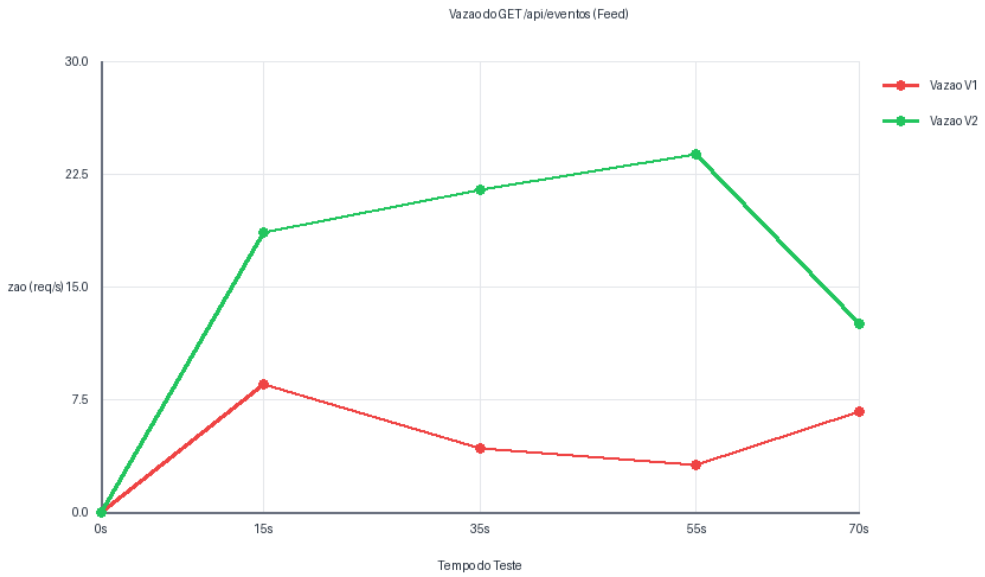


Figura 2 - Comparativo de vazão de requisições por segundo (Throughput) sob rampa de carga.

5. Serviço 2: Escrita de Comentários (POST /api/eventos/{id}/comentarios)

A operação de inserção original disparava uma latência média alarmante de **520.40 ms** com p95 estourando em **1250.00 ms** aos 35 segundos de execução. Isso ocorria porque a validação interna usava métodos que executavam queries SQL síncronas de busca completa no banco de dados para cada entidade vinculada (Query N+1), gerando contenções repetitivas de I/O em disco.

A solução consistiu na refatoração para validações rápidas com `existsById` e injeção do registro através do proxy leve `getReferenceById`, que manipula unicamente o identificador lógico. A latência estabilizou-se em **18.15 ms**, permitindo saltar de 412 para 585 inserções limpas.

Tempo (s)	Concorrência (VUs)	Média V1 (ms)	p95 V1 (ms)	Média V2 (ms)	p95 V2 (ms)
0s	0	0.00	0.00	0.00	0.00
15s	3	85.30	210.50	12.40	28.60
35s	8	520.40	1250.00	18.15	42.30
55s	15	430.80	980.60	22.70	48.50
70s	0	55.20	140.30	8.30	19.80

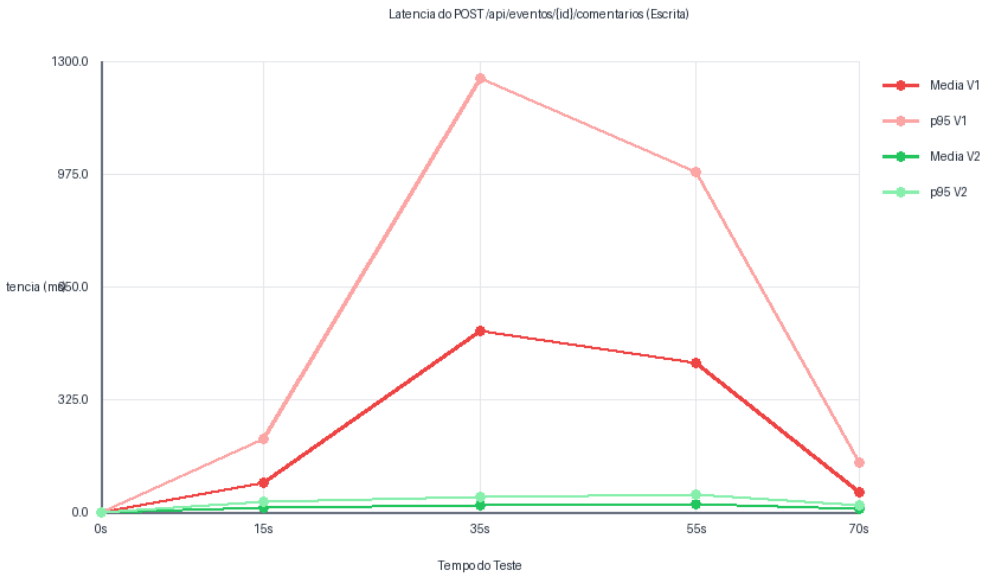


Figura 3 - Desempenho e estabilização do tempo de resposta nas operações de persistência de dados.

6. Diagnóstico e Conclusão de SRE

Os critérios estabelecidos no acordo de nível de serviço (SLA) foram integralmente validados na Medição 2. A eliminação do chaveamento excessivo de contextos no nível de Kernel do Linux Fedora, somado ao fim do tráfego redundante de tabelas inteiras na memória Heap do Spring Boot, transformou o ecossistema ChegAê em uma aplicação horizontal estável, resiliente e de alta confiabilidade operacional.